RAG for Hungarian documents

Which embedder to use?

- Problem
- Solution
- Retrieval Evaluation

Problem

- Create a chatbot for the **ClearService** company
- Company data: **Hungarian**

```
## Fizetés
- A fizetés 1800-2000 euró körüli havonta nettó
- Órabér alapján számolódik, gyorsasági prémiumokkal kiegészítve
- A fizetés két részből áll: magyar alapbérből és német elszámolásból, amit egy összegben utalnak a bankszámlára a hónap 15-én
- A vasárnapi és ünnepnapi munkákra 80% pótlék jár
- A német fizetés 2 részből áll: a magyar alapbérből és a német elszámolásból, ami egy összegben 15-én utalódik a saját bankszámlára
- A magyar havi alapbér NEM ELŐLEG, hanem része a német fizetésnek
- Akinek Revolut/TransferWise bankszámlája van, az azonnal megkapja az elutalt fizetést

## Nyelvtudás
- Német nyelvtudás nem szükséges a jelentkezéshez
- A munkához szükséges alapvető kifejezéseket és kommunikációt a cégnél tanítják meg
- Németországban kötelező nyelvoktatást fog kapni, hogy elsajátítsa a legfontosabb, munkához szükséges kifejezéseket
...
```

Solution

- Build a RAG system
- Evaluate the retriever part
- Plot results

Embedder Models

1. `PP-MINILM` - ST - **paraphrase-multilingual-MiniLM-L12-v2**
2. `NOMIC` - Ollama - **nomic-embed-text**
3. `MINILM` - Ollama - **all-minilm:latest**
4. `OPENAI-ADA` -OpenAI - **text-embedding-ada-002**
5. `OPENAI-3 SMALL` -OpenAI - **text-embedding-3-small**
6. `GEMINI` - Gemini - **embedding-001**
7. `BGE-M3` - ST - **BAAI/bge-m3**
8. `HUBERT` - ST - **NYTK/sentence-transformers-experimental-hubert-hungarian**

Dataset

- Data for ingestion: `data/clearservice/topics.txt`
- Question set: `data/clearservice/cs_qa.csv`

Retriever Evaluation

- Vector DB: **FAISS**
- Question set: **50** questions
- Metrics:

1. `MRR` - Mean Reciprocal Rank
2. `Recall@1`
3. `Recall@3`

Results - Table

Model	MRR	Recall@1	Recall@3
BGE-M3	0.90	0.86	0.96
PP-ML-MINILM	0.84	0.78	0.92
OPENAI-ADA	0.80	0.72	0.90
OPENAI-3 SMALL	0.80	0.72	0.94
NOMIC	0.71	0.64	0.80
MINILM	0.59	0.46	0.74
GEMINI	0.50	0.38	0.68
HUBERT	0.48	0.38	0.68

Semantic vs Lexical Search

Model	MRR	Recall@1	Recall@3
BGE-M3 (best semantic)	0.90	0.86	0.96
HUBERT (worst semantic)	0.48	0.38	0.68
BM25 (**lexical**)	0.77	0.68	0.80

Results

MRR, Recall@1, Recall@3

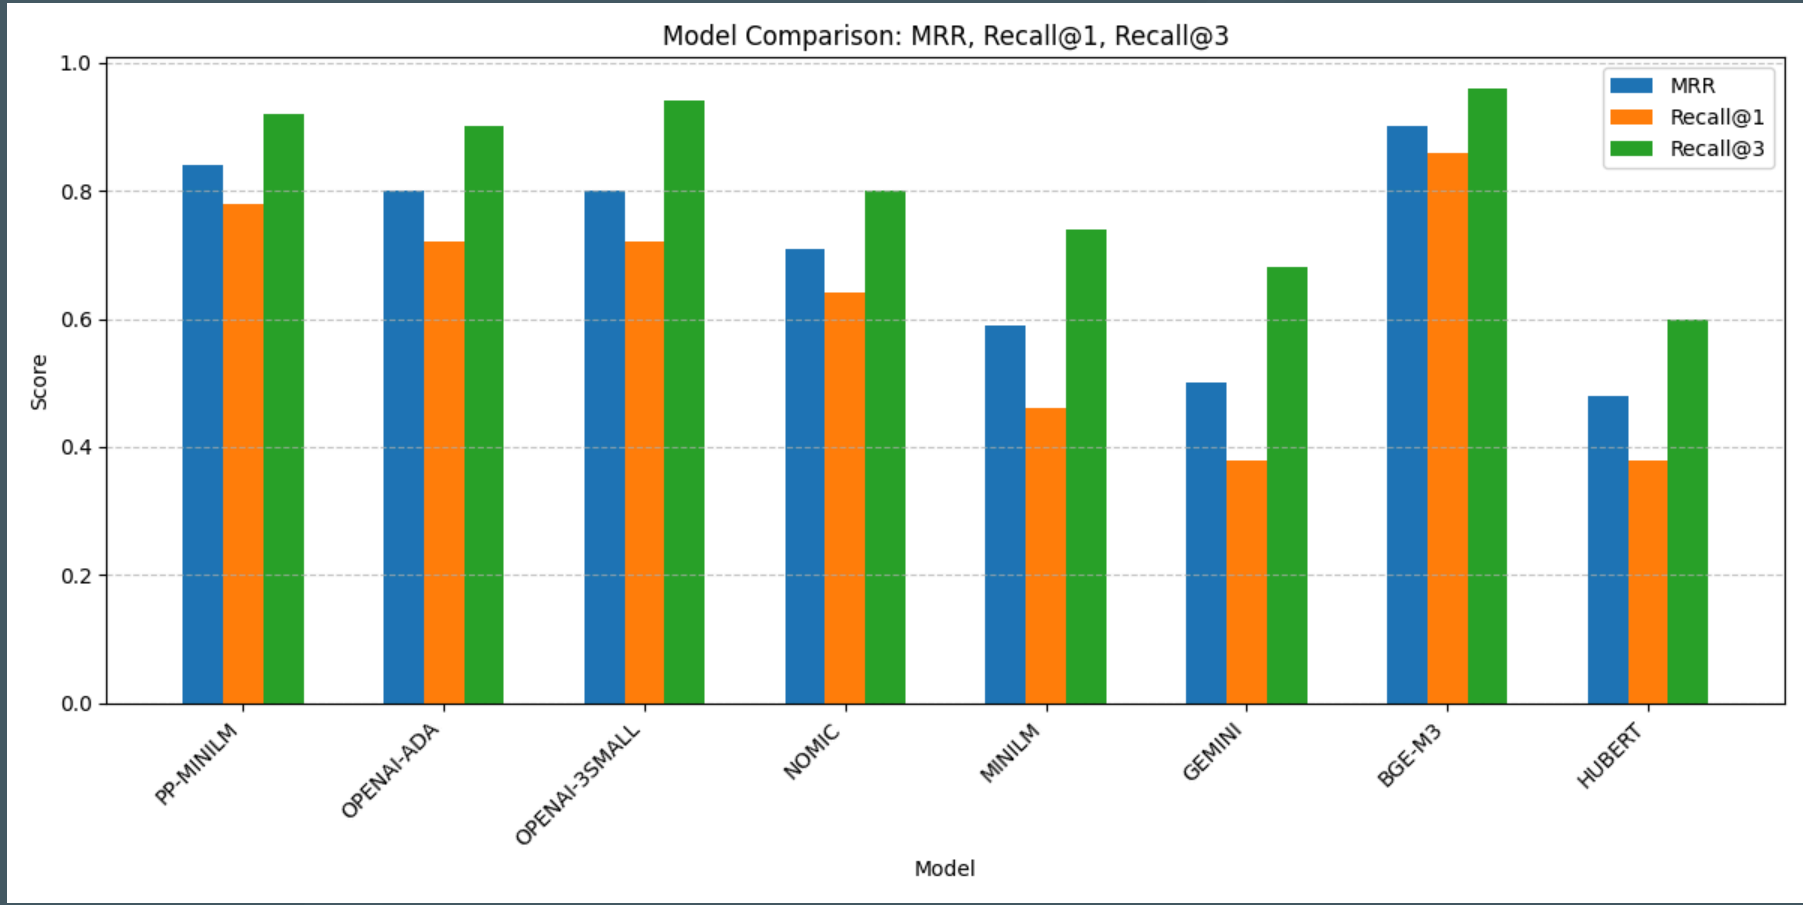

Results

Recall@3

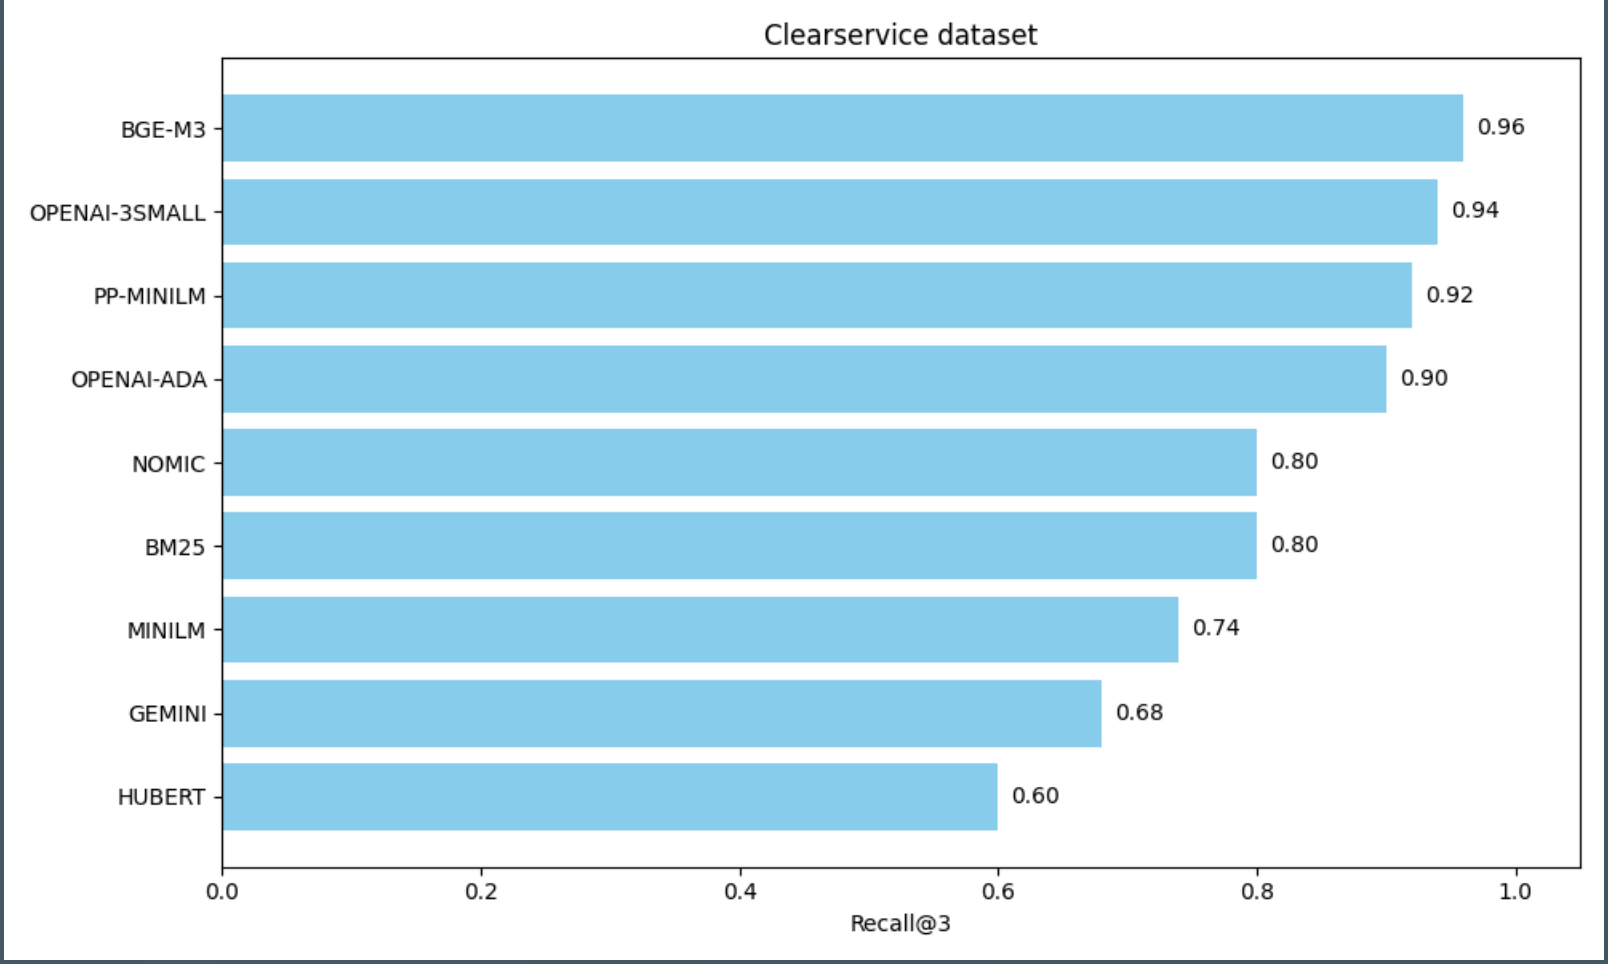

Best Models

Model	Provider	Dim.	Context
BGE-M3	Sentence-Transformers	1024	8192 tokens
PP-MINILM	Sentence-Transformers	384	256 tokens
OPENAI-3SMALL	OpenAI	1536	8192 tokens

Winner

The `BAAI/bge-m3 model`, developed by **Beijing Academy of Artificial Intelligence (BAAI)**, is a multilingual, multi-task, and multi-vector embedding model designed for high-performance retrieval and semantic search across languages and tasks.

References

- Massive Text Embeddings Leaderboard
- Harang Peter: Mennyire tudnak magyarul az embedding-ek?, 2025.01.09.